

# Chapitre 5



Suivi de régions d'intérêt

# Pourquoi faire un suivi?

## □ Suivi d'objets

- Exemple: Suivi des participants d'une réunion.



# Plan du chapitre

---

- ❑ Suivi de régions d'intérêt
  - Définition du suivi
  - Modèles d'apparence utilisés en suivi
    - ❑ Modèle discriminatif versus modèle génératif
    - ❑ Exemple de modèles typiquement utilisés en suivi
  - Modèles de mouvement
    - ❑ Suivi par détection
    - ❑ Suivi par recherche optimisée
  - Mise à jour du modèle d'apparence
  - Suivi multiobjet : association des données

# Définition du suivi

---

- ❑ Le suivi vise tout simplement à mettre en correspondance un objet vu dans une image avec le même objet observé dans une image subséquente.
  
- ❑ Cela permet de :
  - Déterminer les mouvements d'un objet;
  - Établir ses interactions avec d'autres objets;
  - Extraire graduellement des informations sur l'objet (reconnaître la personne, ses actions).

# Modèles d'apparence utilisés en suivi

---

- ❑ Modèle discriminatif versus modèle génératif
  - Pour faire la mise en correspondance d'un objet d'une trame à l'autre, il faut être capable de le distinguer d'une trame à l'autre.
  - Il faut donc pouvoir le distinguer des autres objets d'intérêt dans la scène, ainsi que le distinguer de l'arrière-plan.
  - Il existe deux façons de faire ces distinctions.

# Modèle discriminatif vs génératif

---

## □ Modèle génératif

- C'est le premier type de modèle qui a été utilisé en suivi.
- Un modèle génératif décrit seulement l'objet d'intérêt.
- Exemple : Je veux suivre une personne vêtue de rouge. Dans ce cas, on pourrait modéliser la personne par son histogramme. Une comparaison d'histogrammes permet de localiser la personne.
- Un modèle génératif a une complexité plus faible, et ne demande aucun apprentissage.

# Modèle discriminatif vs génératif

---

## □ Modèle discriminatif

- C'est un modèle qui est utilisé seulement récemment.
- Un modèle discriminatif décrit un objet par rapport aux objets qui l'entourent.
- Exemple : Je veux suivre une personne vêtue de rouge, mais pas vêtue de bleu et de vert. Pour localiser une personne, il faut recourir à une classification, i.e. Vérifier si la personne appartient à la classe objet d'intérêt plutôt qu'à la classe objets distracteurs.
- Le modèle est plus complexe et requiert un apprentissage.

# Modèles d'apparence utilisés en suivi

---

## □ Modèle par points

- Le modèle par points est un modèle où l'objet est décrit par des points caractéristiques tels que SIFT, SURF, FREAK, etc.
- La correspondance est trouvée en comparant la similarité des points du modèle avec une région d'intérêt candidate, et en calculant le nombre de points appariés.
- Par sa nature, le modèle par points est utilisé uniquement comme modèle génératif.



# Modèles d'apparence utilisés en suivi

---

## ❑ Modèle par points

### ■ Avantages :

- ❑ Robuste aux occlusions;
- ❑ Robuste aux changements d'échelle;
- ❑ Robuste aux changements de luminosité;
- ❑ Très discriminatif;
- ❑ Permet une localisation précise.

### ■ Inconvénients :

- ❑ Dépend de la visibilité des points. Les points peuvent ne plus être visibles quand le point de vue change.

# Modèles d'apparence utilisés en suivi

---

## □ Modèle par région

- Le modèle par région est un modèle qui décrit l'apparence de tous les pixels de la région. Une grande variété de modèles peut être utilisée. En voici quelques-uns.
- Histogramme de couleurs ou gradients de la région : La correspondance est trouvée en calculant la distance entre les histogrammes du modèle et de la région candidate.
- L'histogramme peut être utilisé dans un modèle discriminatif ou génératif.

# Modèles d'apparence utilisés en suivi

---

## □ Modèle par région

- Collection dense de descripteurs locaux (SIFT, FREAK, BRIEF, LSS, etc.): La correspondance est trouvée en calculant la distance entre les descripteurs correspondants du modèle et de la région candidate.
- La collection dense de descripteurs locaux peut être utilisée dans un modèle discriminatif ou génératif.
- Normalement pas invariant à l'échelle.

# Modèles d'apparence utilisés en suivi

---



## □ Modèle par région

- Collection de sous-régions: Chaque sous-région est décrite sous forme d'histogramme ou de vecteur de pixels. La correspondance est trouvée en calculant la distance entre les sous-régions correspondantes (ou non) du modèle et de la région candidate. Une sous-région peut être rectangulaire ou être un superpixel.
- La collection de sous-régions peut être utilisée dans les modèles génératifs si la position des sous-régions est fixe, mais elle est plus facile à utiliser dans les modèles discriminatifs où une approche de classification est utilisée. Ainsi, les sous-régions n'ont pas à être à une position fixe sur l'objet.

# Modèles d'apparence utilisés en suivi

## □ Modèle par région


- Modèle épars (sparse model): La région est représentée par une combinaison linéaire de patrons (templates).



# Modèles d'apparence utilisés en suivi

## □ Modèle par région

- Modèle épars: La correspondance est trouvée pour la région candidate qui requiert le moins de patrons pour reconstruire le modèle (d'où le nom de modèle épars, le modèle doit pouvoir être reconstruit avec peu de patrons pour qu'il y ait correspondance).



# Modèles d'apparence utilisés en suivi

---

## □ Modèle par région

- Par sa nature, le modèle épars est un modèle génératif.

# Modèles d'apparence utilisés en suivi

---

## □ Modèle par région

### ■ Avantages :

- Robuste aux changements de points de vue;
- Assez robuste aux changements d'échelle (varie selon le modèle);

### ■ Inconvénients :

- Pas très robustes aux occlusions (sauf, si on utilise des sous-régions)
- Souvent sensible aux changements d'illumination.



# Modèles d'apparence utilisés en suivi

---

## □ Modèle par contour

- Le modèle par contour décrit une région d'intérêt par son contour. Il peut s'agir d'un modèle comme on a vu au chapitre précédent, ou un modèle de contour actif (ce qui suppose un chevauchement important de la région d'intérêt entre deux trames consécutives).
- Pour un modèle comme au chapitre précédent, le même type de distance est utilisé pour la correspondance, en ce qui concerne les modèles de contour actif, il n'y a pas de recherche de correspondances.
- Utilisé comme modèle génératif uniquement.

# Modèles d'apparence utilisés en suivi

---

## □ Modèle par contour

### ■ Avantages :

- Permet de bien délimiter la région (pas un rectangle englobant);
- Robuste aux changements d'échelle, si graduels;
- Robuste aux changements de luminosité;

### ■ Inconvénients :

- Sensible aux occlusions;
- Sensible aux changements de pose des objets;
- Pas de validation de la correspondance (modèle actif).

# Modèles de mouvement

---

- ❑ Le modèle de mouvement vise à réduire l'espace de recherche pour localiser un objet d'intérêt dans une trame.
- ❑ Une approche vorace, qui vérifierait toutes les positions dans l'image (et à plusieurs échelles), n'est pas ce qui est le plus efficace, quoique récemment, les nouvelles méthodes de détection d'objets combinées à l'évolution de la puissance de calcul rendent cette opération possible.

# Suivi par détection

---

- ❑ Le suivi par détection (tracking-by-detection) est une nouvelle approche de suivi. Elle opère en 1 ou 2 étapes :
  1. Un détecteur est appliqué sur l'image pour trouver la localisation d'objets appartenant à une classe d'objets connue a priori (exemple : un détecteur d'humain).
  2. Chaque rectangle englobant correspondant à une détection positive est comparé avec l'instance de l'objet recherché (exemple : un humain en particulier).

L'étape 2 est optionnelle si un classificateur spécialisé existe pour l'objet.

# Suivi par détection


---

- ❑ Exemple, détecteur HOG (Histogram of Oriented Gradients):
  - La région à décrire est divisée en cellules qui sont à la base de blocs en recouvrement. L'histogramme d'orientations de gradients est calculé dans chaque cellule. Et ensuite, les résultats des cellules sont propagés dans les blocs pour calculer leurs histogrammes.
  - Le descripteur HOG est un vecteur des histogrammes des blocs. La taille du descripteur dépend du nombre de blocs nécessaire pour couvrir la région.

# Suivi par détection

---

- ❑ Exemple, détecteur HOG (Histogram of Oriented Gradients):
  - Les descripteurs sont ensuite fournis à un classificateur SVM pour apprendre l'apparence de la classe de l'objet d'intérêt. Des exemples positifs et négatifs sont fournis.



# Suivi par détection

---

- ❑ Exemple, détecteur HOG (Histogram of Oriented Gradients):
  - La détection est réalisée en glissant un rectangle de détection partout dans l'image et à plusieurs échelles.
  - À la suite de ce processus, on a plusieurs candidats d'humains dans l'image.
  - Il faut donc comparer les candidats d'humains avec le modèle de l'objet suivi à l'aide d'un modèle d'apparence.

# Suivi par détection

---

## □ Avantages :

- Permet de gérer facilement les mouvements brusques et les déplacements instantanés très grands;
- Modèle discriminatif, donc robustes aux distracteurs dans l'arrière-plan.

## □ Inconvénients :

- Doit connaître à l'avance la classe de l'objet à suivre, ou on doit l'apprendre en ligne (donc avec peu de données).



# Modèles de mouvement

---

- ❑ La deuxième approche de suivi est par recherche optimisée.
- ❑ Dans cette approche, le suivi est vu comme une recherche du maximum dans la distribution de probabilités du modèle dans l'image.
- ❑ En effet, si on positionne le modèle partout dans l'image, la distance entre le modèle et le contenu de l'image nous donnera une image de probabilités. Le maximum correspond à la position du modèle dans l'image.

# Modèles de mouvement

---

- ❑ La recherche optimisée vise à estimer la distribution de probabilités sans considérer l'image en complet.
- ❑ On suppose que l'objet ne se déplace pas beaucoup dans l'image entre 2 trames.
- ❑ On verra :
  - Le suivi par décalage vers la moyenne (en 2 versions)
  - Le suivi par filtre de particules

# Suivi par décalage vers la moyenne

## □ Procédure Mean-Shift (Décalage vers la moyenne)

- Consiste à calculer le centre de masse à l'intérieur d'une région d'intérêt.
- Centre de masse:

$$x_c = \frac{m_{10}}{m_{00}} = \frac{\sum_{x,y \in R} x^1 y^0 f(x,y)}{m_{00}} = \frac{\sum_{x,y \in R} x \cdot f(x,y)}{m_{00}}$$

$$y_c = \frac{m_{01}}{m_{00}} = \frac{\sum_{x,y \in R} x^0 y^1 f(x,y)}{m_{00}} = \frac{\sum_{x,y \in R} y \cdot f(x,y)}{m_{00}}$$

$$\text{avec } m_{00} = \sum_{x,y \in R} x^0 y^0 f(x,y) = \sum_{x,y \in R} f(x,y)$$

# Suivi par décalage vers la moyenne

---

## □ Procédure Mean-Shift

- Ensuite, on décale la région d'intérêt pour que le centre de celle-ci corresponde au centre de masse calculée.



# Suivi par décalage vers la moyenne

---



## □ Suivi Mean-Shift sans noyau

- Il faut d'abord créer un modèle de ce qu'on veut suivre, compatible avec la procédure Mean-Shift.
- Il faut donc définir une masse pour laquelle on veut trouver le centre.
- Une façon possible est d'utiliser le nombre d'occurrences d'une couleur. Une couleur se répétant souvent aura un poids élevé dans l'image. Cela suppose que l'objet à suivre a des couleurs distinctives.

# Suivi par décalage vers la moyenne

## □ Suivi Mean-shift sans noyau

- Exemple: On choisit la région d'intérêt et calcule son histogramme:



# Suivi par décalage vers la moyenne

---

## □ Suivi Mean-shift sans noyau

- On remplace la valeur de chaque pixel par le nombre d'occurrences de sa couleur dans l'histogramme du modèle.
- On obtient une distribution de probabilité. En pratique, on ne fait pas l'opération sur toute l'image.



# Suivi par décalage vers la moyenne

---

## □ Suivi Mean-shift sans noyau

- À partir de la région d'intérêt de la trame précédente, on applique la procédure Mean-Shift sur la trame courante jusqu'à convergence.
- Il y a convergence quand le centre de masse ne se déplace plus.
- Exemple MATLAB: MeanShiftTracker.m



# Suivi par décalage vers la moyenne

---

## □ Suivi Mean-shift sans noyau


### ■ Exemple:

- Après déplacement du visage, la région d'intérêt de la trame précédente est mal positionnée.
- On applique la procédure Mean-Shift avec les pixels dans la région d'intérêt. Le centre de masse n'est pas au centre de la région.



# Suivi par décalage vers la moyenne

- ❑ Suivi Mean-shift sans noyau
  - Exemple:
    - ❑ On calcule le centre de masse et on y centre la région d'intérêt jusqu'à convergence.
    - ❑ La convergence est définie comme un déplacement de la région d'intérêt inférieur à un seuil en pixel.



# Suivi par décalage vers la moyenne

---

- ❑ Suivi Mean-Shift avec un noyau
  - On peut modéliser l'objet avec n'importe quel type d'histogramme.
  - Compare une région modèle avec une région de la même dimension dans l'image.
  - On veut minimiser la différence d'apparence entre le modèle et une région de l'image.
  - On utilise une métrique basée sur le coefficient de Bhattacharyya.
  - Exemple MATLAB: KernelTracker.m

# Suivi par décalage vers la moyenne

---

## □ Suivi Mean-Shift avec un noyau

- Le coefficient de Bhattacharyya permet de comparer deux distributions discrètes de probabilité.
- Il est défini comme:

$$\rho(y) = \rho(p(y), q) = \sum_{u=1}^m \sqrt{p_u(y)q_u}$$

où  $q_u$  est la distribution de probabilité du modèle, et  $p_u(y)$  est la distribution de probabilité de la région d'intérêt centrée en  $y$ .

# Suivi par décalage vers la moyenne

---

## □ Suivi Mean-Shift avec un noyau

- Pour converger vers le centre de masse (maximiser la similarité), il faut se déplacer selon le gradient de la similarité en appliquant la procédure Mean-Shift avec:

$$x_c = \frac{\sum_{x,y \in R} x \cdot \omega(x, y)}{\sum_{x,y \in R} \omega(x, y)}$$

$$y_c = \frac{\sum_{x,y \in R} y \cdot \omega(x, y)}{\sum_{x,y \in R} \omega(x, y)}$$

$$\omega(x, y) = \sqrt{\frac{q_u \mid x, y \in u}{p_u \mid x, y \in u}}$$

où  $u$  est la classe  $u$  de l'histogramme

# Suivi par décalage vers la moyenne

---

## □ Suivi Mean-shift avec noyau

### ■ Les étapes sont similaires:

1. Création du modèle. On peut donner plus de poids dans l'histogramme aux pixels du centre de la région d'intérêt. Le noyau pour assigner les poids doit être isotropique.
2. Initialise la position de la région d'intérêt dans la nouvelle trame par la position à la trame précédente.

# Suivi par décalage vers la moyenne

---

## □ Suivi Mean-Shift avec noyau

3. Trouve les poids  $\omega(x,y)$  en calculant l'histogramme de distribution de probabilité dans la nouvelle région d'intérêt.
4. Calcule le centre de masse par la procédure Mean-Shift avec la maximisation du coefficient de Bhattacharyya.
5. Vérifie le critère de convergence. S'il n'y a pas convergence retourne à l'étape 2 et fait les traitements à partir de la nouvelle position.

# Suivi par décalage vers la moyenne

---

## □ Avantages :

- Méthode simple et rapide;
- Adapté aux modèles par histogramme (assez courant);
- Pas besoin de connaître à l'avance la classe des objets suivis.

## □ Inconvénients :

- Ne gère que les petites déplacements, car il faut un recouvrement avec l'objet à la trame précédente.



# Suivi par filtre de particules



---

- ❑ Suivi avec filtre de particules (Particle filter, CONDENSATION)
  - On estime la distribution de probabilités par échantillonnage
  - Compare une région modèle avec plusieurs régions choisies aléatoirement.
  - Adapté à tous les modèles par région.
  - On veut minimiser la différence d'apparence entre le modèle et une région de l'image.
  - On utilise une métrique pour calculer la distance entre le modèle et les régions dans l'image (selon le modèle utilisé).

# Suivi par filtre de particules

## □ Algorithme CONDENSATION

1. Initialisation: Il faut choisir une région modèle et la modéliser. On peut utiliser tous modèles d'apparence, comme par exemple l'histogramme de la région.




# Suivi par filtre de particules

---

## □ Algorithme CONDENSATION

1. Initialisation: On doit choisir un nombre de particules (régions candidates) qu'on positionne et dimensionne aléatoirement pour la trame suivante à partir de la région modèle sélectionnée.



# Suivi par filtre de particules

---

## □ Algorithme CONDENSATION

### 1. Initialisation (façon simpliste):

Par exemple (en matlab) pour choisir au hasard la position et la dimension de  $i$  particules:

□ `PFX(i)=PFX(1)+round(2*Regionsize(1)*(rand-0.5));`

□ `PFY(i)=PFY(1)+round(2*Regionsize(1)*(rand-0.5));`

□ `Regionsize(i)=Regionsize(1)+round(Regionsize(1)/3*rand);`



# Suivi par filtre de particules

---

## □ Algorithme CONDENSATION

2. Suivi: Pour la trame courante, on compare la région modèle avec les particules sélectionnées à la trame précédente.

Si on utilise une modélisation par histogramme, on peut comparer les régions avec une distance comme par exemple la distance de Bhattacharyya.

# Suivi par filtre de particules

## □ Algorithme CONDENSATION

2. Suivi: On obtiendra des valeurs de similarité pour chaque particule. Par exemple, pour 40 particules (plus grand==plus similaire):

Probab =

Columns 1 through 7

0.92456	0.89855	0.7012	0.94916	0.53266	0.96818	0.85504
---------	---------	--------	---------	---------	---------	---------

Columns 8 through 14

0	0.92869	0.49202	0.96356	0.97962	0.97373	0.97704
---	---------	---------	---------	---------	---------	---------

Columns 15 through 21

0.9266	0.84715	0.96692	0.81528	0.85117	0.98713	0.97318
--------	---------	---------	---------	---------	---------	---------

Columns 22 through 28

0	0.9127	0.86853	0.80012	0.59683	0	0
---	--------	---------	---------	---------	---	---

Columns 29 through 35

0.8997	0.95443	0.79683	0.82177	0.98179	0.90744	0
--------	---------	---------	---------	---------	---------	---

Columns 36 through 40

0.97944	0.98592	0.8797	0.97734	0.65975
---------	---------	--------	---------	---------

# Suivi par filtre de particules

---

## ❑ Algorithme CONDENSATION

2. Suivi: Certaines particules sont similaires, d'autres le sont moins ou pas du tout. La particule la plus similaire est choisie comme le nouvel état du suivi (Position et taille courante de l'objet suivi). On peut aussi faire la moyenne des positions des particules les plus similaires.



# Suivi par filtre de particules

---

- ❑ Algorithme CONDENSATION
  - 3. Suivi: Certaines particules sont similaires, d'autres le sont moins ou pas du tout. On doit choisir les particules pour la prochaine trame. On se base sur la qualité des particules (similarité la plus grande).





# Suivi par filtre de particules

---

## □ Algorithme CONDENSATION

3. Suivi: On calcule le poids des particules courantes à l'aide de la similarité. Le poids d'une particule est proportionnel à sa valeur de similarité divisée par la somme des valeurs de similarité.

Les particules de la prochaine trame sont positionnées en fonction des poids des particules de la trame courante.

On associe plus de particules dans la trame suivante dans le voisinage des particules les plus similaires de la trame courante.

# Suivi par filtre de particules

---

## □ Algorithme CONDENSATION

### 3. Suivi:

Pour obtenir les particules de la prochaine itération, on utilise l'échantillonnage par importance (importance sampling). La procédure est similaire à un tirage avec remise dans une urne. Le nombre de boules dans l'urne est proportionnel au poids de la particule.



# Suivi par filtre de particules

---

## □ Algorithme CONDENSATION

3. Suivi: La position des particules et leur taille sont déterminées au hasard.
4. On recommence l'étape 2.

## □ Exemple MATLAB: *PartFilter.m*

# Suivi par filtre de particules

---

## □ Avantages :

- Très robuste (gère mise à l'échelle, rotation, translation);
- Utilisable avec une très grande variété de modèles.
- Pas besoin de connaître la classe de l'objet à l'avance.

## □ Inconvénients :

- La précision dépend du nombre de particules, et un grand nombre de particules est exigeant en calculs.

# Mise à jour du modèle d'apparence

---

- ❑ Pour obtenir un suivi robuste, le modèle de la région d'intérêt doit être mis à jour, car le point de vue/illumination de l'objet change.
- ❑ C'est un problème difficile, et plusieurs méthodes de suivi souffrent du problème de dérive (drift).
- ❑ Le problème de dérive origine de l'inclusion de l'arrière-plan lors de la mise à jour du modèle.

# Mise à jour du modèle d'apparence

---

- ❑ En effet, lorsqu'on fait une mise à jour du modèle, on doit se baser sur la région sélectionnée par l'algorithme de suivi. Celle-ci peut :
  - Être mal positionnée : il faudrait donc pouvoir évaluer la qualité du suivi, et déterminer si on doit faire une mise à jour ou non.
  - Inclure des parties d'arrière-plan. Celles-ci contamaine graduellement le modèle : il faut donc essayer d'éliminer l'arrière-plan.

# Mise à jour du modèle d'apparence

---

- ❑ En effet, lorsqu'on fait une mise à jour du modèle, on doit se baser sur la région sélectionnée par l'algorithme de suivi. Celle-ci peut :
  - Inclure d'autres objets lors d'occlusions : il faut donc être capable de déterminer les cas d'occlusion.

# Mise à jour du modèle d'apparence

---

## □ Solutions possibles:

### ■ Problème d'inclusion d'arrière-plan

- On utilise un noyau qui permet de mettre plus d'importance sur les informations au centre de la région. Exemple, un noyau gaussien (très courant). Ainsi, on atténue la contribution des informations d'arrière-plan.
- On fait une segmentation dans la région sélectionnée pour séparer l'objet de l'arrière-plan.



# Mise à jour du modèle d'apparence

---

## □ Solutions possibles:

### ■ Problème d'erreurs de suivi ou d'occlusions

- Le suivi peut souvent être évalué par l'ordre de grandeur de la valeur de la meilleure distance, ou le ratio de la distance avec le deuxième meilleur candidat;
- Avec un modèle par points ou par sous-région, il possible de déterminer les parties fiables et non fiables d'une région.
- On peut aussi utiliser un deuxième modèle pour confirmer le premier (principe des Supporters/Contributors, ou 2<sup>ième</sup> modèle d'apparence).

# Mise à jour du modèle d'apparence

---

- ❑ Le modèle d'apparence est mis à jour :
  - Par substitution (très rare);
  - Par une moyenne (ou fonction) pondérée (très fréquent);
  - Par substitution ou ajout dans un ensemble de représentations possibles.

# Suivi multiobjet : association des données

---

- ❑ Il arrive que l'on doit suivre plus qu'un objet. Dans ce cas, on peut :
  - Faire  $n$  suivis d'objet individuel et supposer qu'il n'y a pas d'erreurs. Pas toujours fiable si des objets sont très similaires, avant, pendant, et après une occlusion.
  - Faire  $n$  suivis d'objet individuel, et valider l'association des données.

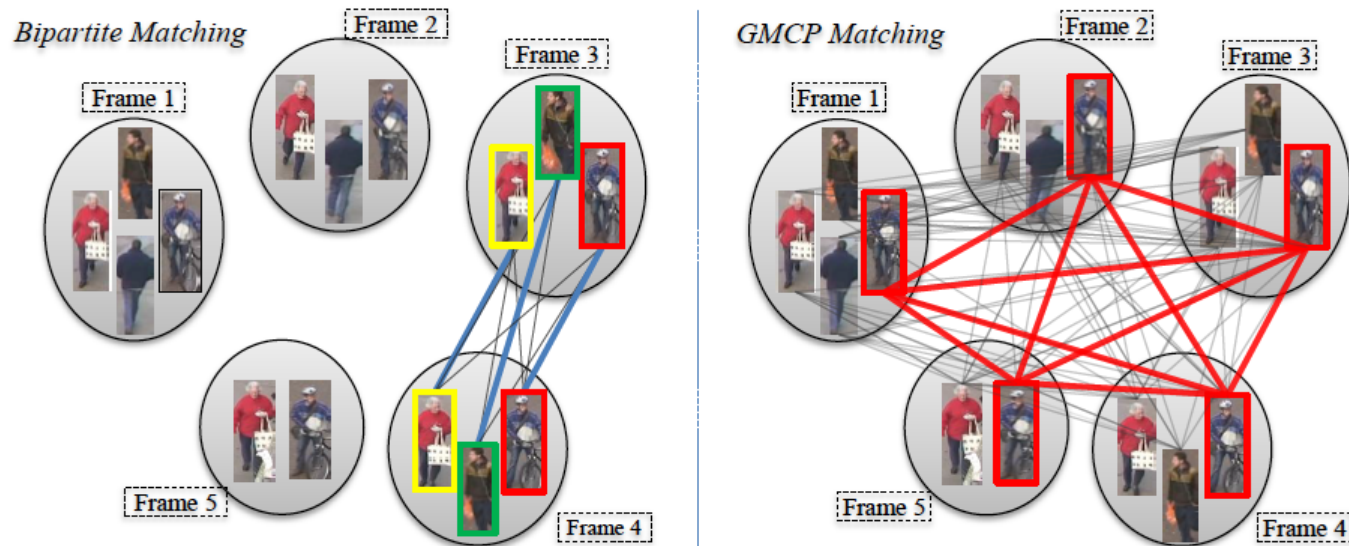
# Suivi multiobjet : association des données

---

- ❑ Association des données:
  - Réalisée en général à l'aide d'un graphe, où les nœuds représentent les objets présents à chaque trame.
  - Le suivi donne les associations les plus probables, mais il faut aussi vérifier les autres possibilités.
  - On peut utiliser un graphe bipartite, dans ce cas, la décision finale est prise à chaque trame, ou on peut utiliser un graphe qui couvre un plus grand espace temporel.

# Suivi multiobjet : association des données

## □ Association des données:



# Bibliographie

---

- H.N. Charif, S.J. McKenna, Tracking the activity of participants in a meeting, Machine Vision and Applications, Vol.17, No. 2, 2006,pp. 83-93
- D. Comaniciu et al., Kernel-Based Object Tracking, IEEE Transactions on Pattern Analysis and Machine Intelligence, Vol. 25, No. 5, 2003, pp. 564-577
- M. Isard, A. Blake, CONDENSATION – Conditional Density Propagation for Visual Tracking, International Journal of Computer Vision 29(1), 1998, pp. 5–28
- D.A. Forsyth, J. Ponce, Computer Vision: A Modern Approach, Prentice Hall, 2002
- A.R. Zamir, A. Dehghan, M. Shah, GMCP-Tracker: Global Multi-object Tracking Using Generalized Minimum Clique Graphs, in ECCV 2012
- X. Mei, H. Ling, Robust Visual Tracking using L1 Minimization, in ICCV 2009
- N. Dalal, B. Triggs, Histograms of Oriented Gradients for Human Detection, in CVPR 2005
- K. Zhang, L. Zhang, M.H. Yang, Real-Time Compressive Tracking, in ECCV 2012
- M.D. Beitenstein, F. Reichlin, B. Leibe, E. Koller-Meier, L. Van Gool, Robust Tracking-by-detection using a detector confidence particle filter, in ICCV 2009
- V. Belagiannis, F. Schubert, N. Navab, S. Ilic, Segmentation Based Particle Filtering for Real-Time 2D Object Tracking, in ECCV 2012
- Z. Hong, X. Mei, D. Tao, Dual-Force Metric Learning for Robust Distracter-Resistant Tracker, in ECCV 2012